

Natural Language Processing 101

Muhammad Yazid Supriadi, S.Kom, M.Kom
STT Terpadu Nurul Fikri



Muhammad Yazid Supriadi, S.Kom, M.Kom

Educational History

Bachelor’s Degree in Informatics (2017-2021)	STT Nurul Fikri
Master’s Degree in Computer Science (2023-2025)	Budi Luhur University

Work Experience

2018-2021	Assistant Lecturer at STT Nurul Fikri
2021	IT Engineer at Timoda Laksmindo Perkasa
2021 - now	Developer Engineer at Pelindo Solusi Digital

Contact

Email	yazid@dosen.nurulfikri.ac.id
Linkedin	(26) Muhammad Yazid Supriadi LinkedIn
Whatsapp, Telegram	087870792385

Outline

1. Introduction to NLP & AI Era
(Natural Language Processing 101)
2. NLP Pipeline & Preprocessing
3. Linguistic Processing
4. Text Representation
(Traditional)
5. Machine Learning for NLP
6. Probabilistic & Language
Modeling
7. Sentiment Analysis End-to-End
8. UTS
9. Named Entity Recognition (NER)
10. Neural Network Fundamentals untuk processing
teks
11. Recurrent Neural Network
12. Attention & Transformer
13. Pretrained Models & Transfer Learning
14. Large Language Models & RAG
15. Text Generation & Responsible AI
16. UAS



Text Data is Everywhere



WIKIPEDIA

25 years of the free encyclopedia

Search Wikipedia

Search

Donate Create account Log in

Natural language processing

71 languages

Contentshide

(Top)

History

- Symbolic NLP (1950s – early 1990s)
- Statistical NLP (1990s–present)

Approaches: Symbolic, statistical, neural networks

- Statistical approach
- Neural networks

Common NLP tasks

- Text and speech processing
- Morphological analysis
- Syntactic analysis
- Lexical semantics (of individual words in context)
- Relational semantics (semantics of

ArticleTalk

ReadEditView historyTools

From Wikipedia, the free encyclopedia

This article has multiple issues. Please help improve it or discuss these issues on the talk page. (Learn how and when to remove these messages)

Natural language processing (NLP) is the processing of *natural language* information by a computer. NLP is a subfield of *computer science* and is closely associated with *artificial intelligence*. NLP is also related to *information retrieval*, *knowledge representation*, *computational linguistics*, and *linguistics* more broadly.^[1]

Major processing tasks in an NLP system include: *speech recognition*, *text classification*, *natural language understanding*, and *natural language generation*.

History [edit]

Further information: History of natural language processing

Natural language processing has its roots in the 1950s.^[2] Already in 1950, *Alan Turing* published an article titled "*Computing Machinery and Intelligence*" which proposed what is now called the *Turing test* as a criterion of intelligence, though at the time that was not articulated as a problem separate from artificial intelligence. The proposed test includes

Part of a series on

Artificial intelligence (AI)



Major goals	[show]
Approaches	[show]
Applications	[show]
Philosophy	[show]
History	[show]
Controversies	[show]
Glossary	[show]

Dengan korpus data teks yang cukup besar, model dapat mempelajari pola-pola bahasa


Natural Language Processing itu apa.?

Natural Language


Natural language is the system of communication used by humans in speech and writing. **Jurafsky & Martin (2009, 2023)** – *Speech and Language Processing*


A language that has developed naturally in use, as opposed to an artificial or constructed language.
Oxford Dictionary

Natural language tidak dirancang, tetapi berkembang secara bertahap melalui proses evolusi biologis, sosial, dan budaya.



- Jurafsky & Martin (Speech and Language Processing) mendefinisikan NLP sebagai studi komputasional terhadap bahasa manusia yang mencakup pemodelan struktur linguistik dan pembelajaran statistik.
- Margrit Betke, Yiwen Gu (2024), Natural Language Processing adalah bidang kecerdasan buatan dan linguistik yang berkaitan dengan interaksi antara komputer dan bahasa manusia (alami).
- Tujuan dari Natural Language Processing adalah komputer bisa mengerti, menafsirkan, dan menghasilkan Bahasa selayaknya manusia






Natural Language Processing



Natural Language Understanding



Natural Language Generation



- Komputer **tidak bisa langsung memahami teks mentah (unstructured text)**.
- Teks harus diubah menjadi **representasi terstruktur (structured data)** agar bisa diproses secara komputasional.


-- Unstructured--

Tolong beliin telur, terigu dan minyak goreng di warung

-- Structured--

```
<items>
<item id="1">telur</item>
<item id="2">terigu</item>
<item id="3">minyak goreng</item>
</items>
```

History and evolution of NLP



- 1950 – Turing Test

Alan Turing memperkenalkan **Turing Test** untuk mengukur apakah mesin bisa berkomunikasi seolah-olah manusia. Konsep ini menjadi ide awal bahwa mesin *bisa memahami bahasa manusia*.

- Penelitian awal NLP fokus pada *aturan bahasa* yang dibuat secara manual oleh linguist (pakar bahasa).

- **ELIZA** (1964–67)

Program pertama yang meniru percakapan melalui pencocokan pola (pattern matching) tanpa pemahaman sebenarnya.

Welcome to

```
EEEEEE LL      IIII  ZZZZZZ  AAAAA
EE      LL      II    ZZ    AA  AA
EEEEEE LL      II    ZZ    AAAAAA
EE      LL      II    ZZ    AA  AA
EEEEEE LLLLLL IIII ZZZZZZ AA  AA
```

Eliza is a mock Rogerian psychotherapist.
The original program was described by Joseph Weizenbaum in 1966.
This implementation by Norbert Landsteiner 2005.

```
ELIZA: Is something troubling you ?
YOU:   Men are all alike.
ELIZA: What is the connection, do you suppose ?
YOU:   They're always bugging us about something or other.
ELIZA: Can you think of a specific example ?
YOU:   Well, my boyfriend made me come here.
ELIZA: Is it important to you that your boyfriend made you come here ?
YOU:   He says I'm depressed much of the time.
ELIZA: I am sorry to hear that you are depressed.
YOU:   It's true. I am unhappy.
ELIZA: Can you explain what made you unhappy ?
YOU:
```


- Rule-based terbukti sangat terbatas, karena bahasa manusia sangat kompleks
- Mulai digunakan model statistik seperti **n-gram models**, probabilistic parsing, Hidden Markov Models (HMM), Support Vector Machines (SVM), dll.

Dampak:

- ✓ Komputer mulai *belajar pola bahasa dari data nyata*
- ✓ Bisa memperkirakan kata berikutnya berdasarkan konteks statistik
- ✓ Semakin meningkat kemampuan ekstraksi informasi

- Pada era 1990-an sampai awal 2010, Algoritma ML mulai menggantikan rules based , Dimana komputer tidak dirancang secara manual, tapi *belajar hubungan dari data*.
- Algoritma ML mulai menggantikan rules: komputer dilatih dari data besar untuk berbagai tugas NLP seperti:
 - Part-of-speech tagging
 - Named Entity Recognition
 - Speech recognition
 - Parsing
- Contoh model machine learning yang digunakan:
 - Support Vector Machine
 - Conditional Random Fields
 - Logistic Regression

NLP mulai menggunakan Neural Network untuk belajar langsung dari data, tanpa banyak fitur buatan manusia.

Pada era ini muncul beberapa terobosan dalam teknologi NLP seperti:

1. Word Embedding (Word2Vec)

- Kata diubah menjadi vektor angka yang mengandung makna.

2. RNN, LSTM, GRU

- Model membaca teks sebagai urutan
- Bisa mengingat konteks sebelumnya

3. Seq2Seq + Attention


- Digunakan untuk machine translation
- Attention membantu model fokus pada kata penting

Transformer Era


Pada tahun 2017, muncul sebuah paper yang diperkenalkan oleh google berjudul “attention is all you need” yang memperkenalkan arsitektur Transformer berbasis *self-attention*.

Model Transformer dapat melihat seluruh kalimat sekaligus tanpa berdasarkan urutan, transformer juga dapat memproses data secara parallel serta dapat menangkap hubungan jarak jauh dalam sebuah kalimat.

Beberapa model transformer seperti:
BERT, GPT-3, GPT-4.



- Mulai tahun 2020 muncul paradigma baru dalam dunia NLP yang disebut Large Language Models (LLMs) dengan menghadirkan beberapa model diantaranya:
 - GPT-3 (2020)
 - PaLM (2022)
 - LLaMA (2023)
- LLMs memiliki beberapa karakteristik yaitu:
 - ✓ Trained on massive data
 - ✓ Few-shot learning
 - ✓ Zero-shot capability
 - ✓ Emergent abilities



Google Search

apa itu natural language processing

✕

🔊

📷

🔍

AI Mode

All

Images

Shopping

Videos

Short videos

News

More

Tools

Sponsored result

Show sponsored result

AI Overview

Natural Language Processing (NLP) atau Pemrosesan Bahasa Alami adalah cabang kecerdasan buatan (AI) yang memungkinkan komputer memahami, menginterpretasikan, memanipulasi, dan menghasilkan bahasa manusia, baik dalam bentuk teks maupun suara. NLP menggabungkan ilmu linguistik komputasional, statistik, serta machine learning untuk memproses bahasa yang tidak terstruktur secara natural. [Amazon Web Services \(AWS\)](#) +3

Fungsi dan Komponen Utama NLP

NLP menjembatani kesenjangan antara komunikasi manusia dan pemahaman mesin, memungkinkan interaksi yang lebih alami. [YouTube](#)

Pemahaman Konteks: Mesin tidak hanya membaca kata, tetapi memahami konteks.

Show more

Apa Itu NLP (Natural Language Processing)? - IBM

Translated — Pemrosesan bahasa alami (NLP) adalah subbidang ilmu komputer dan...

IBM

Apa itu Pemrosesan Bahasa Alami (NLP)? - AWS

Apa Itu Pemrosesan Bahasa Alami (NLP)? Pemrosesan bahasa alami (NLP) adalah teknologi yang memungkinkan komputer...

[Amazon Web Services \(AWS\)](#) +3

School of Computer Science – BINUS University


<https://socs.binus.ac.id> · 2013/06/22 · [Translate this page](#)

Natural Language Processing


22 Jun 2013 — Natural Language Processing (NLP) merupakan salah satu cabang ilmu AI yang berfokus pada pengolahan bahasa natural. Bahasa natural adalah bahasa ... [Read more](#)

People also ask

Chatbot and Virtual Assistant



Machine Translation



Sentiment Analysis



Your product
is hard to use

NEGATIVE



Your service is
doing okay

NEUTRAL



Wow, I feel this
is so amazing

POSITIVE

All Games > Free to Play Games > Dota 2

Dota 2

Community Hub



Every day, millions of players worldwide enter battle as one of over a hundred Dota heroes. And no matter if it's their 10th hour of play or 1,000th, there's always something new to discover. With regular updates, there's always something new to discover. With regular updates, there's always something new to discover.

81% of the 14,858 user reviews in the last 30 days are positive.

RECENT REVIEWS: **Very Positive** (14,858)

ALL REVIEWS: **Very Positive** (861,774)

RELEASE DATE: 9 Jul, 2013

DEVELOPER: Valve

PUBLISHER: Valve

Popular user-defined tags for this product:

[Free to Play](#) [MOBA](#) [Strategy](#) [Multiplayer](#) [PvP](#) [+](#)

Voice Recognition

Hey Siri, who are you?

Product Case Study of Apple's Voice Assistant



Information Extraction

Information Extraction

Subject: **curriculum meeting**

Date: January 15, 2012

To: Dan Jura

Event: Curriculum mtg

Date: Jan-16-2012

Start: 10:00am

End: 11:30am

Where: Gates 159


Hi Dan, we've now scheduled the curriculum meeting.

It will be in Gates 159 tomorrow from 10:00-11:30. ▼

-Chris

Create new Calendar entry


Spam Detection




Captioning



Large Language Model



Industri	Use Case
Tech	Customer service otomatis, AI assistant internal perusahaan
Finance	Fraud detection, Sentiment Analysis Pasar
Retail	Analisis review pelanggan, Personalization berbasis deskripsi produk
Media and Social Media	Hate Speech Detection, Social Media Bot Detection, Fake News Detection
Healthcare	Ekstraksi informasi dari rekam medis
Legal	Contract Analysis
HR	CV screening, Employee Sentiment Monitoring
Pendidikan	AI Tutor, Plagiarism Detection



- **Phonology** adalah level analisis bahasa yang berfokus pada struktur dan pola bunyi (speech sounds) dalam suatu bahasa. Dalam konteks Natural Language Processing (NLP), khususnya pada sistem yang menerima input suara (speech-based system). Fonologi berperan dalam memahami bagaimana bunyi diproduksi, dibedakan, dan ditafsirkan menjadi unit bahasa yang bermakna.
- Secara sederhana, cara kerja fonologi dalam system NLP sebagai berikut:
Sound signal → Feature extraction → Phoneme recognition → Word recognition → Sentence interpretation
- Tanpa pemrosesan fonologi:
 - Sistem tidak bisa membedakan bunyi mirip (misalnya /p/ dan /f/)
 - Tidak bisa memahami aksen atau variasi pengucapan
 - Tidak bisa menangkap emosi atau maksud pembicara



1. Phonetic Rules (Aturan Fonetis)

Berhubungan dengan **realisasi bunyi secara fisik** dalam kata. Phonetic Rules berfokus pada bagaimana bunyi diucapkan (artikulasi, durasi, intensitas). Sebagai contoh kata “data” bisa diucapkan dengan berbeda seperti :

/ˈdeɪ.tə/ (American)

/ˈdɑː.tə/ (British)

/da.ta/ (Indonesian English accent)

2. Phonemic Rules (Aturan Fonemik)

- Berkaitan dengan variasi bunyi ketika kata digabungkan dalam konteks kalimat.
- Fonem adalah unit bunyi terkecil yang membedakan makna.
- Sebagai contoh dalam bahasa Inggris: “handbag” sering terdengar seperti “hambag”.

3. Prosodic Rules (Aturan Prosodik)

- Berkaitan dengan intonasi, tekanan (stress), dan ritme dalam kalimat.
- Penting untuk memahami: Perbedaan pernyataan vs pertanyaan serta ekspresi emosi.
- Sebagai contoh : “Kamu pergi.” (intonasi turun → pernyataan) berbeda dengan “Kamu pergi” (intonasi naik → perintah tersirat)

Morphology adalah level analisis bahasa yang mempelajari **struktur internal kata**, khususnya bagaimana kata tersusun dari **morpheme** (unit makna terkecil dalam bahasa).

Morpheme (Morfem) adalah unit terkecil dari kata yang memiliki arti semantic

– contoh : “nir-”, “pra-”, “-isasi”, “ber-”, “-an”, “-logi”

Analisis morfologi adalah pekerjaan mengurai kata ke dalam morfemnya :

- nirkabel -> nir + kabel (tidak / tanpa)
- standardisasi -> standard + isasi (proses)
- kelima -> ke + lima
- Googlers -> (Google + er) + s (plural)
- unlockable -> un + (lock + able) ?
-> (un + lock) + able ?

Dalam NLP, morfologi membantu sistem memahami:

- Waktu (tense)
- Jumlah (singular/plural)
- Aspek (sedang, sudah)
- Bentuk kata turunan

Lexical Level (POS Tagging)

- **Lexical level** berfokus pada pemahaman makna kata secara individual. Baik manusia maupun sistem NLP harus menentukan:
 1. Part-of-Speech (POS) suatu kata
 2. Makna (sense) yang tepat berdasarkan konteks
 3. Representasi semantik dari kata tersebut
- Sistem NLP harus menentukan kelas kata berdasarkan **konteks** menggunakan **contextual embeddings**, sehingga kata yang sama bisa memiliki representasi berbeda tergantung konteksnya.
- Sebagai contoh:
 - “They **launch** the product.” → *launch* = verb
 - “The **launch** was successful.” → *launch* = noun
- Tanpa lexical disambiguation dalam pemrosesan bahasa:
 - Parsing bisa salah
 - Meaning extraction gagal
 - Machine translation bisa keliru

Lexical Level (Word Sense Disambiguation (WSD))

Beberapa kata memiliki **lebih dari satu makna (polysemy)**.

Contoh kata: **launch** dalam Bahasa Inggris

Makna 1:

“NASA will launch a rocket.” → meluncurkan

Makna 2:

“The company launched a new product.” → memperkenalkan

Makna 3:

“We rented a launch to cross the river.” → perahu besar

- Di level leksikal, sistem harus menentukan:
 - Makna mana yang digunakan?
 - Apakah ini tindakan? benda? event?



Lexical Level (Representasi Semantik)

- Pada representasi semantik, kata bisa diganti dengan representasi makna abstrak.
- Representasi semantik tidak menyimpan definisi eksplisit, tetapi:
 - Mengubah kata menjadi vektor numerik
 - Kata dengan makna mirip → vektor berdekatan
- Contoh:
“launch”, “release”, “introduce”
→ ketiga kata tersebut memiliki kedekatan semantik dalam ruang vektor
- Pada NLP Modern model representasi semantic bisa menggunakan model seperti Word2Vec, FastText

Syntactic Level

Syntactic level berfokus pada analisis **struktur gramatikal kalimat**.



Tujuannya adalah mengetahui:

- Siapa subjek?
- Apa predikatnya?
- Apa objeknya?
- Bagaimana hubungan antar kata?

Untuk itu, sistem NLP membutuhkan:

1.Grammar (aturan tata bahasa)

2.Parser (alat untuk membangun struktur kalimat)



Semantic Tasks (Word Sense Disambiguation)

Sebuah kata dalam bahasa alami biasanya bisa memiliki beberapa arti yang berbeda.

- Orang tua Ellen bekerja di bidang komputasi linguistik.
 - Ellen melihat ada orang tua tersesat di jalan.
- Untuk banyak pekerjaan (question answering, translation), harus ditentukan arti kata yang tepat untuk tiap kata yang ambigu dalam kalimat.

Semantic Tasks (Semantic Role Labeling)

Untuk tiap klausa, menentukan peran semantik (semantic role) dari masing masing noun phrase yang merupakan argumen dari verba.

agent patient source destination instrument

- Budi drove Jessica from Jakarta to Surabaya in his Civic.
- The hammer broke the window.

- Nama lainnya “case role analysis,” “thematic analysis,” dan “shallow semantic parsing

Semantic Tasks (Semantic Parsing)

Semantic parser memetakan kalimat dalam bahasa alami ke dalam representasi semantik (logical form) yang lengkap dan detail.

- Untuk beberapa aplikasi output yang diharapkan adalah yang bisa dieksekusi langsung oleh program lainnya.

Contoh : diterjemahkan menjadi bentuk logika / query / struktur terformat.

“Tampilkan restoran Jepang di Jakarta yang buka sekarang.”

Find(Restaurant)

Cuisine = Japanese

Location = Jakarta

Open = Now

Discourse menganalisis makna dalam teks yang terdiri dari beberapa kalimat. Discourse melihat **hubungan antar kalimat**, bukan hanya kalimat secara terpisah.

Sebagai Contoh:

Andi membeli laptop baru.

Dia membelinya kemarin karena yang lama rusak.

Jika dianalisis terpisah:

- “Dia” tidak jelas siapa.
- “yang lama” tidak jelas apa.

Discourse processing menyambungkan:

- Dia → Andi
- yang lama → laptop lama

Dua Process utama dalam discourse yaitu :

- Anaphora Resolution
- Discourse Structure Recognition

- **Anaphora Resolution**

Anaphora Resolution proses menentukan referensi kata Ganti

Contoh:

Siti bertemu Rina. Dia sangat senang.

Pertanyaan:

“Dia” merujuk ke siapa?

Sistem NLP harus memilih referensi yang benar berdasarkan konteks.

.

- **Discourse Structure Recognition**

Discourse Structure Recognition berguna untuk menentukan fungsi tiap bagian teks.

Sebagai contoh pada artikel berita dapat dibagi menjadi beberapa bagian seperti:

1. Ringkasa Utama
2. Main Story
3. Background/Previous Events
4. Kutipan Narasumber
5. Prediksi / Expectation

Pragmatic

- Pragmatik adalah memahami makna berdasarkan konteks, situasi, dan pengetahuan dunia, bukan hanya dari kata-kata yang tertulis.
- Pragmatik melibatkan:
 - Intent (niat)
 - World knowledge (pengetahuan dunia)
 - Situational context (konteks situasi)
 - Social norms (aturan sosial)
- Pragmatik dianggap sulit karena melibatkan:
 - Pengetahuan dunia
 - Pemahaman budaya
 - Konteks sosial
 - Pemahaman ironi dan sarkasme
 - Pemahaman niat

Tantangan dalam NLP

1. Tantangan Linguistik

- **Ambiguitas** (polysemy, struktur kalimat ambigu)
- **Konteks & pragmatik** (ironi, sarkasme, implikatur)
- **Variasi bahasa** (slang, dialek, code-switching)

2. Tantangan Teknis

- Multilingual & low-resource language
- Domain shift & generalisasi
- Hallucination (LLM)
- Evaluasi & reasoning kompleks

3. Tantangan Etis & Sosial

- Bias & fairness
- Data privacy & keamanan
- Black-box (interpretability)
- Biaya komputasi & dampak lingkungan



Source

Rodenbeck, S. (n.d.). *Natural Language Processing 101*. Rosen Center for Advanced Computing.

Betke, M., & Gu, Y. (n.d.). *Introduction to Natural Language Processing*. Boston University, CS 640 – Artificial Intelligence.

Mansouri, B. (2023). *Natural Language Processing – Session 1: Introduction*. University of Southern Maine.

Sarkar, D. (2019). *Text Analytics with Python: A Practitioner's Guide to NLP* (2nd ed.). Apress.

Speech and Language Processing – Jurafsky, D., & Martin, J. H.

Foundations of Statistical Natural Language Processing – Manning, C. D., & Schütze, H.

Introduction to Information Retrieval – Manning, C. D., Raghavan, P., & Schütze, H.

Thank you guys!